



УНИВЕРЗИТЕТ У НИШУ
ЕЛЕКТРОНСКИ ФАКУЛТЕТ



СНАТ TTS: НЕУРОНСКА СИНТЕЗА ГОВОРА И АНАЛИЗА ПРИРОДНОСТИ,
РАЗУМЉИВОСТИ И ВРЕМЕНА СИНТЕЗЕ

СЕМИНАРСКИ РАД

Предмет: Вештачка интелигенција у говорним и аудио-сигнаlima

Студент:

Немања Стојановић 2126

Ментор:

проф. др Јелена Николић

Садржај

1. Увод.....	2
2. Синтеза говора као област обраде сигнала.....	2
3. Основне компоненте TTS система	3
4. Класични TTS и conversational TTS	5
5. ChatTTS: опис система	5
6. Повезани модели и теоријска основа.....	7
6.1. WaveNet.....	7
6.2. HiFi-GAN.....	7
6.3. Style Tokens	7
6.4. Glow и flow-based модели.....	8
6.5. Neural codes и токенизација аудио сигнала	8
7. Метрике за евалуацију TTS система	9
7.1. Време синтезе	9
7.2. Трајање генерисаног аудиоја	9
7.3. Real-time factor.....	9
7.4. Природност	9
7.5. Разумљивост	10
7.6. Број грешака у изговору	10
7.7. Сигналне карактеристике.....	10
8. Методологија експеримента	11
9. Репродукција резултата.....	12
10. Резултати експеримента.....	12
11. Оригинални допринос	16
11.1. Утицај дужине текста	16
11.2. Утицај стила реченице.....	16
11.3. Утицај садржаја текста	17
11.4. Утицај језика.....	18
12. Дискусија	18
13. Ограничења рада.....	19

14. Закључак	20
15. Литература.....	21

1. Увод

Синтеза говора, односно text-to-speech (TTS), претвара писани текст у говорни сигнал и припада области обраде говорних и аудио сигнала [11], [12]. Код оваквих система није довољно да се добије било какав звучни запис. Потребно је да говор буде разумљив, природан, стабилан и употребљив у конкретној примени. Данас се TTS користи у виртуелним асистентима, едукативним алатима, навигацији, апликацијама за приступачност, системима за читање текста, играма, корисничкој подршци и интерактивним дијалошким системима.

Тема овог рада је ChatTTS, неуронски систем за синтезу говора који је усмерен на конверзациони говор [1]. За разлику од класичних TTS система, код којих је главни циљ најчешће јасно и неутрално читање текста, conversational TTS системи треба да производе говор који звучи као део разговора. Због тога су, поред разумљивости, важни ритам, паузе, интонација, експресивност и стабилност изговора у различитим типовима улазног текста.

Рад је подељен у три целине. У првој је дата теоријска основа синтезе говора и преглед повезаних неуронских TTS приступа. Друга целина описује покретање ChatTTS система и генерисање аудио фајлова за припремљене текстуалне примере. У трећој се анализира како дужина текста, стил реченице, технички садржај и језик утичу на време синтезе, real-time factor, природност, разумљивост и број грешака у изговору.

Истраживачко питање рада гласи:

Колико је ChatTTS погодан за конверзациону синтезу говора и како промена улазног текста, стила и садржаја утиче на природност, разумљивост и време синтезе?

2. Синтеза говора као област обраде сигнала

TTS систем прима текст као улаз, а као излаз генерише дигитални аудио сигнал. Иако се крајњи резултат посматра као говор, поступак синтезе повезује више области: обраду природног језика, акустичко моделовање, генеративно моделовање, дигиталну обраду сигнала и перцептивну процену квалитета.

Традиционални TTS системи могу се поделити на неколико група:

1. формантне системе, који користе правила и акустичке моделе говорног тракта,
2. конкатенативне системе, који спајају унапред снимљене говорне јединице,

3. статистичке параметарске системе, који моделују акустичке параметре говора,
4. неуронске системе, који користе дубоке неуронске мреже за генерисање говорних репрезентација или директно аудио сигнала.

Неуронски TTS системи су значајно унапредили квалитет синтезе, пре свега зато што боље моделују сложену везу између текста, фонетског садржаја, прозодије и аудио сигнала. Уместо ручно дефинисаних правила, они уче обрасце из великих говорних скупова података. Због тога говор може да звучи природније, али се истовремено повећавају захтеви за рачунарским ресурсима и пажљивом евалуацијом резултата.

Код класичних формантних система говор се гради помоћу модела резонанција говорног тракта. Такав приступ може бити веома контролисан, али обично звучи вештачки јер је тешко ручно описати све варијације природног говора. Конкатенативни системи користе другачију идеју: уместо да генеришу сваки акустички детаљ, они бирају и спајају делове претходно снимљеног говора. Њихов квалитет може бити висок када се улаз добро поклапа са снимљеном базом, али се јављају проблеми на местима спајања и код реченица које захтевају стил или прозодију који нису довољно заступљени у корпусу [11].

Статистички параметарски системи представљају прелаз ка модерном TTS-у. Они не чувају готове јединице говора, већ предвиђају параметре као што су спектрална обвојница, основна фреквенција и трајање. Предност је мања меморијска сложеност и лакша контрола гласа, док је мана често превише изглађен и мање природан звук. Неуронски системи су преузели исти општи задатак, али су заменили ручно конструисане параметарске моделе дубоким мрежама које могу да науче богатије односе између текста и акустике.

Због тога се савремени TTS често посматра као низ условљених генеративних задатака. Писани текст се најпре претвара у репрезентацију која носи лингвистичку информацију. Акустички модел затим предвиђа временски развијену говорну репрезентацију, најчешће *mel* спектрограм или дискретне аудио токене. На крају вокодер или декодер од те репрезентације прави *waveform*. Оваква подела је корисна јер се одвојено могу пратити грешке у нормализацији текста, прозодији и квалитету самог аудио сигнала.

3. Основне компоненте TTS система

Савремени TTS систем обично се састоји од неколико повезаних компоненти.

Прва компонента је обрада текста. Улазни текст се чисти, нормализује и претвара у облик погодан за модел. Овај корак обухвата обраду бројева, скраћеница, интерпункције, великих слова, специјалних симбола и језичких разлика. На пример, записи као што су "3.5 seconds", "GPU" или "NASA" могу бити проблематични ако систем нема јасну информацију о очекиваном изговору.

Нормализација текста је посебно важна јер TTS систем не добија звук као улаз, већ писани запис који често има више могућих изговора. Број "2026" може се читати као година или као низ цифара. Скраћеница "ASR" може се изговорити као појединачна слова, као енглески акроним или као локализована форма. Интерпункција такође није само правописни детаљ: тачка, зарез, двотачка и знак питања утичу на паузе и интонацију. Без добре припреме улаза модел може да произведе говор који је граматички разумљив, али у комуникационом смислу неприродан.

Код српског језика додатни проблем је однос ћирилице, латинице и енглеских уметнутих речи. Модел који је боље обучен на енглеском може добро изговорити техничке термине, али погрешити српске падежне облике или мешовите реченице. Зато је у практичном делу ручно припремање улаза, као што је раздвајање слова у "G P U" или "T T S", део саме методологије, а не споредна козметичка измена.

Друга компонента је лингвистичка или фонетска репрезентација. Неки системи текст претварају у фонеме, док други раде директно са текстуалним токенима или subword јединицама. Избор репрезентације утиче на стабилност изговора, нарочито код речи које су ретке, стране или нису добро заступљене у подацима за обучавање.

Трећа компонента је акустички модел. Он предвиђа акустичку репрезентацију говора, на пример mel спектрограм или дискретне аудио токене. Ова компонента повезује садржај текста са особинама говора као што су трајање, интонација, ритам и паузе.


Mel спектрограм је чест избор зато што компресује waveform у временско-фреквенцијску слику која је ближа људској перцепцији звука. Уместо да модел директно предвиђа десетине хиљада аудио одмерака у секунди, он предвиђа мањи број временских оквира и фреквенцијских опсега. То поједностављује акустичко моделовање, али захтева посебан вокодер који ће спектрограм претворити назад у таласни облик.

Дискретни аудио токени представљају новији смер. У том приступу неуронски кодек претвара говор у низ индекса из коначног скупа јединица. Такав низ подсећа на текстуалне токене код језичких модела, па се за генерацију говора могу користити слични autoregressive механизми. Цена је то што квалитет зависи од кодека: ако кодек изгуби fine акустичке детаље, каснији генератор их не може у потпуности повратити [20].

Четврта компонента је вокодер. Вокодер претвара акустичку репрезентацију у стварни аудио сигнал. Код неуронских система вокодер је најчешће дубока генеративна мрежа која производи таласни облик високог квалитета. Значајни примери вокодерских приступа су WaveNet и HiFi-GAN [13], [14].

Пета компонента је контрола стила. Код конверзационих система овај део је посебно важан, јер систем треба да разликује неутралну реченицу, питање, узвик, дијалог, паузе и промене експресивности. У литератури су за ову област значајни Style Tokens и сродни приступи који уводе латентне репрезентације говорног стила [15].

Слика 1 приказује како основне компоненте претварају текст у говорни сигнал:



Слика 1: Општи ток синтезе говора, од улазног текста до генерисаног аудио-сигнала

4. Класични TTS и conversational TTS

Класични TTS системи често се процењују према томе колико јасно читају улазни текст. Њихов излаз може бити веома разумљив, али понекад звучи равно, монотонно или неприродно у дијалошком контексту. Такав говор је довољан за читање обавештења, навигационих инструкција или једноставних порука, али није увек погодан за интерактивне асистенте и дијалошке апликације.

Од conversational TTS система очекује се више. Говор треба да звучи као природан одговор у разговору. То подразумева:

- природнију интонацију,
- одговарајуће паузе,
- контролу темпа,
- експресивност,
- стабилан изговор у кратким репликама,
- прилагођавање различитим стилима реченица.

ChatTTS припада овој групи система. Његова вредност није само у томе што претвара текст у аудио, већ у томе да тај аудио звучи довољно природно за апликације у којима систем разговара са корисником.

Разлика између класичног читања и конверзационог говора није само у избору речи. У разговору су важни микропаузе, наглашавање, очекивање одговора, несигурност, кратке реакције и промена темпа. Реченица "Really?" захтева другачији интонациони образац од исте речи у дужем исказу. Слично томе, узвик треба да има више енергије, док објашњавачки пасус мора да остане стабилан и читљив током дужег трајања. Због тога conversational TTS мора да контролише више акустичких димензија истовремено.

У овом раду тај аспект је испитан кроз неколико кратких категорија улазног текста: питање, узвик, дијалошка реплика, бројеви, скраћенице, српски текст и мешовити текст. Такав скуп не омогућава потпуну евалуацију, али је довољан за контролисано поређење појединих случајева. На тај начин може да се види да ли систем подједнако добро ради када се промени само стил или тип садржаја, без промене целе експерименталне поставке.

5. ChatTTS: опис система

ChatTTS је систем за conversational text-to-speech синтезу чији су начин инсталације, подржани језици и основни inference поступак описани у званичном репозиторијуму и PyPI документацији [1], [2]. Експеримент је покренут локално, а моделски фајлови налазе се у директоријуму `asset`. Модел се покреће из Jupyter notebook-а `analiza.ipynb`, који обједињује код, текст и видљиве резултате у складу са концептом рачунарског notebook-а [10]. Помоћне функције за учитавање модела, генерисање аудио фајлова, мерење времена и израчунавање метрика налазе се у `src/tts_experiments.py`.

Извршавање модела заснива се на PyTorch tensor операцијама [3], док се библиотека Transformers користи при учитавању повезаних моделских компонената [7]. Генерисани waveform се претвара у одговарајући tensor и чува као WAV датотека уз подршку torchaudio библиотеке [4].

У практичном делу ChatTTS се посматра као готов inference систем. Не врши се дообучавање, промена архитектуре нити анализа тежина модела, већ се испитује понашање доступног система над пажљиво изабраним улазима. Такав приступ одговара репродукционом делу семинарског рада: циљ је да се покаже да се систем може покренути локално, да генерише аудио и да се његов излаз може мерити објективним и субјективним показатељима.

Пошто је генерација говора стохастички поступак, постављена `seed` вредност побољшава поновљивост, али не гарантује да ће сваки систем добити битски идентичан waveform. На резултат могу утицати верзије библиотека, тип процесора, оптимизације у PyTorch-у и начин чувања аудио фајла. Зато су у раду документовани окружење, верзије пакета, `sample rate` и тачна листа улазних текстова.


Улазни подаци су дефинисани у фајлу `data/text_manifest.csv`. Сваки ред у манифесту садржи:

- `text_id`,
- `language`,
- `category`,
- `style`,
- `text`.

Модел генерише говор на основу колоне `text`. Излазни аудио чува се у директоријуму `generated_audio`, под именом које одговара идентификатору текста. На пример, ред са `text_id` вредношћу `short_neutral` даје фајл `generated_audio/short_neutral.wav`.

Генерисани снимци нису служили само као демонстрација. Они су основа за мерење времена синтезе, трајања аудио сигнала, `real-time factor` вредности, сигналних карактеристика и субјективних оцена природности и разумљивости.

Слика 2 повезује улазне текстове, модел, генерисани аудио и резултате:



Слика 2: Експериментални ток ChatTTS анализе, од текстуалног манифеста до табела и графика

6. Повезани модели и теоријска основа

6.1. WaveNet

WaveNet је један од најзначајнијих неуронских модела за генерисање сировог аудио сигнала [13]. Модел користи ауторегресивни приступ и дилатиране конволуције како би моделовао дугорочне зависности у аудио сигналу. Посебно је важан јер је показао да неуронски модели могу да генеришу говор високог квалитета директно на нивоу таласног облика. Главно ограничење ауторегресивних приступа остаје спорија генерација, пошто се узорци производе секвенцијално.

Ауторегресивна генерација има јасну вероватносну интерпретацију: сваки следећи узорак зависи од претходно генерисаних узорака. То моделу даје велику изражајну моћ, али и рачунску цену. Ако је sample rate 24 kHz, једна секунда звука има 24.000 узорака. Генерисање једног по једног узорака постаје споро за интерактивне примене. Управо тај проблем је мотивисао развој бржих вокодера, паралелних генератора и модела који не раде директно на сваком аудио одмерку.

6.2. HiFi-GAN

HiFi-GAN је генеративни адверсаријални модел за ефикасну и висококвалитетну синтезу говора [14]. Најчешће се користи као вокодер, односно као компонента која mel спектрограм претвара у аудио сигнал. Његова главна предност је добра равнотежа између квалитета и брзине, што је важно за TTS системе од којих се очекује природан говор у разумном времену.

GAN приступ користи две мреже: генератор производи аудио, а дискриминатор покушава да разликује синтетички сигнал од стварног. У вокодерском контексту то помаже да се добију оштрији и природнији детаљи него код једноставних регресионих губитака. Ипак, GAN модели могу бити осетљиви на стабилност обучавања и на неслагање између акустичких репрезентација на којима су обучени и оних које добијају у конкретном TTS систему.

6.3. Style Tokens

Style Tokens уводе идеју да модел може да учи латентне репрезентације говорних стилова без експлицитног означавања сваке емоције или начина говора [15]. Такве репрезентације помажу у контроли експресивности, ритма и интонације. Овај концепт је важан за ChatTTS јер conversational TTS не треба да звучи као неутрално читање реченице, већ као део разговора.

Контрола стила је тешка зато што стил није једна скаларна величина. Он обухвата темпо, распон pitch-а, енергију, паузе, наглашавање, дисање и прагматичку функцију реченице. Два исказа могу имати исти текст, али потпуно различито значење ако се један изговори као питање, други као сумња, а трећи као ироничан одговор. Зато се код conversational TTS-а не може посматрати само да ли су речи исправно изговорене, мора се посматрати да ли је начин изговора прикладан контексту.

6.4. Glow и flow-based модели

Glow је пример flow-based генеративног модела [16]. Flow-based приступи користе инвертибилне трансформације и омогућавају моделовање сложених дистрибуција. У контексту говора, сличне идеје утицале су на развој модела који стабилније и ефикасније генеришу акустичке репрезентације, као у Glow-TTS систему [17]. Иако у овом раду ChatTTS није анализиран на нивоу свих интерних слојева, ова група модела даје користан шири контекст за разумевање генеративних система.

Поред flow-based приступа, важну улогу у развоју TTS-а имају encoder-decoder системи са attention механизмом. Tacotron 2 је показао да се текст може мапирати у mel спектрограм, а затим претворити у waveform неуронским вокодером [18]. Тај двостепени приступ постао је једна од основних парадигми неуронске синтезе говора. Међутим, attention може погрешити код дугих реченица, прескочити део текста или поновити фразу, што је посебно важно код система који треба да буду стабилни у реалној употреби.

FastSpeech је пример non-autoregressive приступа који уводи експлицитније моделовање трајања и омогућава бржу синтезу [19]. Уместо да decoder генерише један по један корак зависно од претходног, модел може паралелније да предвиђа акустичке оквире. То је важно за real-time примене, јер брзина није споредна метрика: интерактивни асистент који касни неколико секунди може бити разумљив на нивоу садржаја, али непријатан за коришћење.

6.5. Neural codec и токенизација аудио сигнала

Савремени TTS системи све чешће користе дискретне аудио токене или неуронске кодеке. Уместо директног предвиђања сваког аудио узорка, говор се може представити низом дискретних јединица које декодер или вокодер касније претвара у аудио. Такав приступ

олакшава генерацију, контролу и повезивање са моделима који раде на сличан начин као велики језички модели.

Неуронски кодек компресује аудио у латентни простор, а затим га реконструише. Ако је тај простор дискретизован, говор се може третирати као секвенца кодова. Предност је што модел више не мора да генерише waveform на нивоу сваког узорка. Уместо тога, он генерише мањи број акустичких симбола, па се могу користити технике сличне језичком моделовању. За conversational TTS то је посебно привлачно, јер се текстуални и аудио токени могу обрађивати у ближим моделским оквирима [20].

Ограничење је што кодек уводи сопствене артефакте. Ако је компресија јака, синтетички говор може имати металичан призвук, губитак високих фреквенција или мање природне прелазе. Зато квалитет крајњег TTS система зависи од три повезана дела: колико добро језички део разуме улаз, колико добро генератор предвиђа акустичке токене и колико верно кодек реконструише waveform.

7. Метрике за евалуацију TTS система

Једна метрика није довољна да опише квалитет TTS система. Зато су у анализи спојене објективне и субјективне мере: брзина синтезе, особине сигнала и утисак слушаоца не морају увек да воде ка истом закључку.

7.1. Време синтезе

Време синтезе мери колико је секунди потребно да модел генерише аудио за дати текст. Ова метрика зависи од дужине текста, сложености модела и хардвера. У овом експерименту синтеза је извршена на CPU окружењу, па су времена већа него што би се очекивало на GPU уређају.

7.2. Трајање генерисаног аудиоја

Трајање аудио сигнала показује колико је дуг генерисани говор. Дужи текст најчешће доводи до дужег аудио сигнала, али однос није потпуно линеаран јер зависи од темпа, пауза и начина изговора.

7.3. Real-time factor

Real-time factor (RTF) представља однос времена синтезе и трајања генерисаног аудио сигнала:

$$\text{RTF} = \text{време_синтезе} / \text{трајање_аудија}$$

Ако је RTF мањи од 1, систем генерише говор брже него што се аудио репродукује. Ако је RTF већи од 1, систем је спорији од реалног времена. У овом експерименту све RTF вредности су веће од 1, што је очекивано за покретање на CPU окружењу.

7.4. Природност

Природност је субјективна оцена тога колико генерисани говор звучи као природан људски говор. У раду је коришћена скала од 1 до 5, где 1 означава веома неприродан говор, а 5 веома природан говор.

У широј TTS евалуацији често се користи Mean Opinion Score (MOS), где више слушаца оцењује исте примере, а затим се рачуна просек. Такав поступак је поузданији од једне оцене јер смањује утицај личних навика слушаоца, квалитета слушалица и очекивања о томе како синтетички говор треба да звучи. У овом раду MOS није спроведен у строгом облику, али је задржана иста логика скале од 1 до 5, како би се добила бар основна перцептивна мера.

7.5. Разумљивост

Разумљивост описује колико се лако разуме изговорени текст. И она је оцењивана скалом од 1 до 5. Говор може бити разумљив, али не потпуно природан, због чега су природност и разумљивост посматране као одвојене оцене.

Раздвајање природности и разумљивости је важно. Снимак може бити јасан, али роботски. У том случају разумљивост је висока, а природност нижа. Обрнуто, говор може имати пријатан глас и ритам, али погрешно изговорити бројеве, стране речи или српске облике. Тада природност на први утисак може бити прихватљива, али разумљивост задатог текста опада. Зато су у табели посебно бележене и грешке у изговору.

7.6. Број грешака у изговору

Број грешака у изговору коришћен је као једноставна мерљива допуна субјективној процени. Грешке могу да обухвате погрешан изговор скраћеница, бројева, страних речи, српских речи или прескакање делова текста.

7.7. Сигналне карактеристике

Поред субјективних оцена, рачунате су и основне сигналне карактеристике: RMS ниво, zero-crossing rate, spectral centroid и процењени pitch. За читавање аудија, спектралне мере и mel спектрограм коришћена је библиотека librosa [5]. Ове мере не замењују слушну процену, али омогућавају да се разлике између примера прикажу и нумерички.

RMS ниво приближно описује просечну енергију сигнала. Виши RMS може указивати на гласнији или енергичнији говор, али не значи аутоматски бољи квалитет. Zero-crossing rate мери колико често сигнал мења знак и може бити осетљив на шум и високофреквенцијске компоненте. Spectral centroid описује где је тежиште спектралне енергије: виша вредност често значи светлији или оштрији звук. Процењени pitch је повезан са основном фреквенцијом гласа и користан је за поређење питања, узвика и неутралних реченица.

Ове мере треба тумачити опрезно. Оне не говоре да ли је реч правилно изговорена, нити да ли је интонација прагматички исправна. На пример, два снимка могу имати сличан RMS и spectral centroid, а да један ипак звучи природније због бољих пауза и наглашавања. Зато је сигнална анализа у раду коришћена као допуна, а не као замена за слушну процену.

8. Методологија експеримента

Експеримент је организован око десет текстуалних примера. Примери су изабрани тако да покрију више услова релевантних за ChatTTS:

1. кратак неутралан текст,
2. средњи пасус,
3. дуги пасус,
4. питање,
5. узвик,
6. дијалошка реплика,
7. текст са бројевима и техничким терминима,
8. текст са скраћеницама,
9. кратак текст на српском језику,
10. мешовити српско-енглески текст.


Овакав избор не проверава само основну способност генерисања говора, већ и понашање система у условима који су практично важни. Посебно су значајни српски и мешовити примери, јер ChatTTS није примарно намењен српском језику. Због тога се ти примери у раду посматрају као анализа ограничења система, а не као очекивано најбољи сценарио.

Експеримент је текао овим редом:

1. учитавање окружења и библиотека,
2. учитавање текстуалног манифеста,
3. учитавање ChatTTS модела из локалних моделских фајлова,
4. генерисање аудио фајла за сваки улазни текст,
5. чување аудио фајлова у директоријум generated_audio,
6. мерење времена синтезе и трајања аудио сигнала,
7. израчунавање RTF вредности,
8. израчунавање сигналних карактеристика,
9. слушна процена природности, разумљивости и грешака у изговору,
10. спајање објективних и субјективних резултата у финалне табеле.

Аудио-датотеке су поред torchaudio тока провераване и обрађиване помоћу SoundFile интерфејса [6]. Структурирање манифеста и резултата изведено је библиотеком pandas [8], док су графици времена, RTF вредности, спектрограма и сигналних карактеристика генерисани библиотеком Matplotlib [9].

Слика 3 повезује категорије улазног текста са објективним и субјективним мерама:



Слика 3: Методологија практичног ChatTTS експеримента и групе излазних мера

9. Репродукција резултата

Основна функционалност ChatTTS система репродукована је генерисањем аудио фајлова за свих десет текстуалних примера. Фајлови су сачувани у директоријуму `generated_audio`, под именима која одговарају идентификаторима из манифеста, на пример `short_neutral.wav`, `question.wav` и `mixed_language.wav`.

Овим је потврђено да локална инсталација модела ради и да систем може да произведе аудио за различите типове улазног текста. Експеримент је покренут у следећем окружењу:

- Python: 3.13.3
- платформа: macOS 15.7.3, arm64
- PyTorch: 2.8.0
- CUDA: није инсталирана
- ChatTTS: installed
- torchaudio: 2.8.0
- librosa: 0.11.0
- soundfile: 0.14.0

Синтеза је извршена на CPU окружењу (CUDA није инсталирана). То је важно за тумачење времена синтезе и RTF вредности.

10. Резултати експеримента


Најважнији резултати за све генерисане примере приказани су у табели 1:

Пример	Карактери	Време синтезе (s)	Трајање аудија (s)	RTF	Природност	Разумљивост	Грешке
short_neutral	82	10.93	4.68	2.34	5/5	5/5	0

medium_paragraph	228	27.62	13.27	2.08	5/5	5/5	0
long_paragraph	465	50.23	23.39	2.15	4/5	5/5	0
question	66	8.93	3.56	2.51	4/5	5/5	0
exclamation	62	6.24	2.92	2.14	5/5	5/5	0
dialogue_reply	100	13.14	6.34	2.07	5/5	5/5	0
numbers_terms	107	17.97	7.38	2.43	5/5	5/5	0
abbreviations	100	14.12	6.15	2.30	5/5	5/5	0
serbian_short	82	13.16	5.56	2.37	3/5	2/5	4
mixed_language	115	17.43	7.68	2.27	3/5	2/5	4

Табела 1: Резултати ChatTTS синтезе за све текстуалне примере


Слика 4 приказује везу броја карактера и времена синтезе:



Слика 4: Време синтезе у зависности од броја карактера улазног текста

Време синтезе расте са бројем карактера, што се јасно види на примерима `short_neutral`, `medium_paragraph` и `long_paragraph`.


Слика 5 пореди RTF вредности свих генерисаних примера:



Слика 5: Real-time factor по текстуалном примеру

Све вредности су веће од 1, па синтеза на коришћеном CPU окружењу није бржа од реалног времена.


Слика 6 приказује временску структуру и спектралну енергију кратког неутралног примера:



Слика 6: Таласни облик и mel спектрограм генерисаног примера short_neutral

На приказу се виде трајање, паузе и расподела енергије у сигналу.

Слика 7 приказује waveform и mel спектрограм дужег примера:



Слика 7: Таласни облик и mel спектрограм генерисаног примера `medium_paragraph`

У поређењу са кратком реченицом, овај пример има дуже трајање и сложенију структуру говора.

11. Оригинални допринос

Оригинални допринос рада је контролисана анализа утицаја улазног текста на квалитет и брзину ChatTTS синтезе. Анализа је подељена на три мерљива правца: дужину текста, стил реченице и садржај/језик текста.

11.1. Утицај дужине текста


За анализу дужине коришћени су примери `short_neutral`, `medium_paragraph` и `long_paragraph`. Време синтезе расте са дужином текста: од 10.93 s за 82 карактера до 50.23 s за 465 карактера. И трајање аудија расте, са 4.68 s на 23.39 s. RTF ипак остаје релативно стабилан, у опсегу од 2.08 до 2.34. То значи да систем на CPU окружењу није real-time, али се однос времена синтезе и трајања аудија не погоршава нагло код дужег текста. Разумљивост остаје 5/5 за сва три примера, док природност код дугог пасуса опада на 4/5.

11.2. Утицај стила реченице

За анализу стила коришћени су примери `question`, `exclamation` и `dialogue_reply`. Сви примери су разумљиви, са оценом 5/5 за разумљивост. Природност је 4/5 за питање и 5/5 за узвик и дијалошку реплику. Разлика није велика, али сугерише да ChatTTS добро генерише кратке конверзационе примере, док интонација питања у овом случају није била једнако уверљива као код узвика или дијалошке реченице.

Питање има највиши RTF међу овим примерима, 2.51, док су вредности за узвик и дијалошку реплику 2.14 и 2.07. Из тога се види да време синтезе не зависи само од броја карактера, већ и од начина на који модел генерише аудио токене и трајање излазног сигнала.

Разлике у процењеном `pitch`-у и RMS енергији између питања, узвика и дијалошке реплике приказане су на слици 8:



Слика 8: Поређење `pitch` и RMS енергије за различите стилове реченица


На тај начин се стил реченице повезује са мерљивим особинама сигнала.

11.3. Утицај садржаја текста

За анализу садржаја коришћени су `numbers_terms` и `abbreviations`. Оба примера имају природност 5/5, разумљивост 5/5 и 0 уочених грешака у изговору. У овом експерименту ChatTTS је успешно обрадио енглеске техничке термине, бројеве и скраћенице из припремљених реченица.

Ипак, део улазног текста је ручно припремљен тако да буде лакши за изговор. На пример, "G P U", "A S R" и "T T S" написани су са размацама између слова. То је једноставан облик нормализације текста и показује да квалитет TTS система не зависи само од модела, већ и од припреме улаза.

Слика 9 приказује како тип садржаја и ручна припрема улаза утичу на разумљивост и број грешака:



Слика 9: Поређење разумљивости и броја грешака за обичан текст, техничке термине и скраћенице након припреме улаза

11.4. Утицај језика

Највеће ограничење примећено је код српског и мешовитог текста. Пример `serbian_short` има природност 3/5, разумљивост 2/5 и 4 грешке у изговору. Пример `mixed_language` има исте субјективне оцене: природност 3/5, разумљивост 2/5 и 4 грешке у изговору.

Овај резултат показује да ChatTTS није једнако стабилан за све језике. Енглески примери добили су високе оцене, док српски и мешовити текст показују проблеме са изговором и разумљивошћу. То је у складу са очекивањем да модел који није примарно оптимизован за српски језик може имати ограничења у синтези српског говора.

12. Дискусија

Резултати показују да ChatTTS успешно генерише разумљив и природан говор за енглеске примере из експеримента. Кратки, средњи и дуги енглески текстови имају високу разумљивост, а технички термини и скраћенице нису довели до грешака у изговору у овом скупу примера. У овако постављеном тесту систем је постигао добре резултате у основним conversational TTS сценаријима на енглеском језику.

Међутим, real-time factor је већи од 1 у свим примерима. То значи да покретање на CPU окружењу није довољно брзо за апликације које захтевају генерисање говора у реалном времену. За практичну примену у интерактивним системима потребан је GPU или оптимизован inference pipeline.

Најзначајније ограничење у експерименту односи се на синтезу српског и мешовитог текста. Ниже оцене природности и разумљивости показују да модел има проблем са стабилношћу изговора када улаз није на језику за који је систем најпогоднији. Ово ограничење је важно за локализоване апликације на српском језику.

Анализа такође показује да припрема улазног текста има значајну улогу. Скраћенице написане као одвојена слова могу бити лакше за синтезу, па се у практичним TTS системима пре самог модела често користи модул за нормализацију текста.

Посебно је важан однос између резултата и постављеног циља. Ако се ChatTTS користи за кратке енглеске реплике у интерактивној апликацији, добијени резултати указују на употребљивост система: природност и разумљивост су високе, а стилови као што су узвик и дијалогски одговор звуче убедљиво у овом малом скупу. Ако је циљ локализована синтеза српског говора, исти резултати указују на ограничење: модел може да произведе аудио, али квалитет није довољно стабилан без додатне адаптације или пажљиве припреме текста.

RTF резултати такође мењају практично тумачење. Систем који има добар аудио квалитет, али RTF већи од 1, погодан је за offline генерисање снимака, аудио материјала или демонстрација. За дијалог у реалном времену потребна је бржа инфраструктура или оптимизовани inference. У супротном, кашњење постаје део корисничког искуства и може да поништи предност природнијег гласа.

Сигналне мере су помогле да се стилске разлике не сведу само на опис "звучи боље" или "звучи горе". Pitch и RMS могу показати да узвик има другачију енергију од питања, а mel спектрограм визуелно приказује трајање, паузе и расподелу енергије. Међутим, оне не смеју бити прецењене: TTS је комуникациони систем, па коначна оцена мора да укључи и разумевање садржаја, природност и прикладност интонације.

13. Ограничења рада

Рад има неколико важних ограничења. Прво, број тест примера је мали. Десет примера је довољно за семинарску демонстрацију и контролисану анализу, али није довољно за широку статистичку процену квалитета модела.

Друго, субјективне оцене потичу од једног слушаоца. За озбиљнију MOS евалуацију било би потребно укључити више слушалаца и применити стандардизовану процедуру оцењивања.

Треће, експерименти су извршени на CPU окружењу. Зато резултати за време синтезе и RTF не представљају најбоље могуће перформансе модела.

Четврто, српски и mixed-language примери анализирани су као ограничење система, али није рађена додатна адаптација модела или фино подешавање за српски језик.

Пето, није извршено поређење са другим TTS системима. Зато се резултати не могу тумачити као доказ да је ChatTTS бољи или гори од алтернатива. Рад показује како се ChatTTS понаша у дефинисаном локалном окружењу и на изабраном скупу реченица.

Шесто, нису систематски испитивани параметри генерације као што су temperature, top-p, seed, speaker embedding или refine-text подешавања. Једна конфигурација је корисна за контролисану анализу, али не показује целокупан простор могућег понашања модела.

Седмо, сигналне мере су основне и не укључују напредније метрике као што су speaker similarity, PESQ, STOI или аутоматска процена MOS-а. Те мере би могле да прошире рад, али би захтевале додатну методологију и пажљиво тумачење.

14. Закључак

У практичном делу покренут је и анализиран ChatTTS систем за синтезу говора. Систем је успешно генерисао аудио фајлове за десет текстуалних примера. Резултати показују да ChatTTS добија високе субјективне оцене за енглеске примере, посебно за неутралне реченице, узвике, дијалошке реплике, бројеве и скраћенице.

Време синтезе расте са дужином текста, али RTF остаје релативно стабилан у већини примера. На CPU окружењу систем није real-time, јер су све RTF вредности веће од 1. Најслабији резултати добијени су за српски и мешовити текст, где су природност и разумљивост знатно ниже, а број грешака у изговору већи.

На основу ових резултата, ChatTTS је погодан за основну конверзациону синтезу говора на енглеском језику. Примена на српски језик захтева опрез, додатну нормализацију текста или модел који је боље прилагођен српском говору.

Резултати не подржавају једноставну оцену да је ChatTTS универзално добар или лош TTS систем, већ показују да његов квалитет зависи од језика, стила, припреме улаза и хардверског окружења. У енглеским примерима систем показује добар потенцијал за conversational TTS. У српским примерима исти поступак открива ограничења која би морала да се реше пре практичне употребе.

Будући рад треба да обухвати већи број реченица, више слушалаца, поређење са бар једним другим TTS системом и посебну анализу параметара генерације. За српски језик најкорисније проширење било би увођење систематске нормализације текста, скупа српских тест реченица и евентуалне адаптације модела. Таква анализа би прецизније

показала да ли је проблем пре свега у моделу, у улазном тексту или у недостатку језички прилагођених података.

15. Литература

- [1] 2Noise Team, “ChatTTS: A generative speech model for daily dialogue,” GitHub repository. <https://github.com/2noise/ChatTTS>.
- [2] Python Package Index, “ChatTTS package documentation.” <https://pypi.org/project/ChatTTS/>.
- [3] A. Paszke et al., “PyTorch: An imperative style, high-performance deep learning library,” in Advances in Neural Information Processing Systems (NeurIPS), vol. 32, 2019.
- [4] Y.-Y. Yang et al., “TorchAudio: Building blocks for audio and speech processing,” in Proc. IEEE Int. Conf. Acoustics, Speech and Signal Processing (ICASSP), 2022.
- [5] B. McFee et al., “librosa: Audio and music signal analysis in Python,” in Proc. 14th Python in Science Conf., 2015, pp. 18-25.
- [6] SoundFile Developers, “Python SoundFile documentation.” <https://python-soundfile.readthedocs.io/>.
- [7] T. Wolf et al., “Transformers: State-of-the-art natural language processing,” in Proc. Conf. Empirical Methods in Natural Language Processing: System Demonstrations (EMNLP), 2020, pp. 38-45.
- [8] W. McKinney, “Data structures for statistical computing in Python,” in Proc. 9th Python in Science Conf., 2010, pp. 56-61.
- [9] J. D. Hunter, “Matplotlib: A 2D graphics environment,” Computing in Science & Engineering, vol. 9, no. 3, pp. 90-95, 2007.
- [10] T. Kluyver et al., “Jupyter Notebooks: A publishing format for reproducible computational workflows,” in Positioning and Power in Academic Publishing: Players, Agents and Agendas, 2016, pp. 87-90.
- [11] P. Taylor, Text-to-Speech Synthesis. Cambridge, UK: Cambridge University Press, 2009.
- [12] D. Jurafsky and J. H. Martin, Speech and Language Processing, 3rd ed. draft. Stanford University, 2026.
- [13] A. van den Oord et al., “WaveNet: A generative model for raw audio,” arXiv:1609.03499, 2016.

- [14] J. Kong, J. Kim, and J. Bae, “HiFi-GAN: Generative adversarial networks for efficient and high fidelity speech synthesis,” in *Advances in Neural Information Processing Systems* (NeurIPS), vol. 33, 2020, pp. 17022-17033.
- [15] Y. Wang et al., “Style tokens: Unsupervised style modeling, control and transfer in end-to-end speech synthesis,” in *Proc. Int. Conf. Machine Learning (ICML)*, 2018, pp. 5180-5189.
- [16] D. P. Kingma and P. Dhariwal, “Glow: Generative flow with invertible 1x1 convolutions,” in *Advances in Neural Information Processing Systems* (NeurIPS), vol. 31, 2018.
- [17] J. Kim, S. Kim, J. Kong, and S. Yoon, “Glow-TTS: A generative flow for text-to-speech via monotonic alignment search,” in *Advances in Neural Information Processing Systems* (NeurIPS), vol. 33, 2020, pp. 8067-8077.
- [18] J. Shen et al., “Natural TTS synthesis by conditioning WaveNet on mel spectrogram predictions,” in *Proc. IEEE Int. Conf. Acoustics, Speech and Signal Processing (ICASSP)*, 2018, pp. 4779-4783.
- [19] Y. Ren et al., “FastSpeech: Fast, robust and controllable text to speech,” in *Advances in Neural Information Processing Systems* (NeurIPS), vol. 32, 2019.
- [20] A. Defossez, J. Copet, G. Synnaeve, and Y. Adi, “High fidelity neural audio compression,” *arXiv:2210.13438*, 2022.